Detector de Vocales en Hiragana mediante entrenamiento con YOLOv8

Diego Raúl Hernández Cardeña

March 11, 2026

Abstract

Este artículo presenta el desarrollo de un sistema de detección automática para reconocer las vocales del silabario japonés Hiragana utilizando modelos de visión por computadora basados en la arquitectura YOLOv8. Se describe el proceso de adquisición de datos, etiquetado, entrenamiento, evaluación y análisis de resultados, así como la construcción de una matriz de confusión para validar el desempeño del modelo.

1 Introducción

El aprendizaje automático y la visión por computadora se han convertido en herramientas esenciales para tareas de reconocimiento de patrones. En este proyecto se desarrolló un modelo capaz de identificar las vocales del hiragana —あ, い, う, え, お—a partir de imágenes capturadas desde distintos dispositivos. El objetivo principal fue construir un sistema funcional que permitiera reconocer estos caracteres de manera confiable y medir su desempeño mediante métricas estándar como precisión, recall y matriz de confusión.

2 Objetivo

Diseñar, entrenar y evaluar un modelo de detección de objetos basado en YOLOv8 para identificar las vocales del hiragana, generando métricas de desempeño que permitan validar la calidad del modelo.

3 Materiales y Métodos

3.1 Adquisición de datos

Se recopilaron imágenes de las vocales del silabario hiragana (*a*, *i*, *u*, *e*, *o*) desde fotografías reales y recursos digitales. Cada imagen fue etiquetada manualmente utilizando la herramienta `LabelImg`, generando archivos `.txt` en formato YOLO que contienen las coordenadas normalizadas de cada carácter.

A continuación, se presenta la distribución del conjunto de entrenamiento:

Table 1: Distribución del conjunto de entrenamiento (imágenes y etiquetas).

Vocal	**Imágenes (train)**	**Etiquetas (train)**
あ	40	40
え	50	50
い	44	44
お	47	47
う	67	67

3.2 Preprocesamiento

Las imágenes fueron organizadas en las carpetas `train` y `val`. Se etiquetaron los caracteres utilizando `LabelImg`, generando archivos en formato YOLO con coordenadas normalizadas.

3.3 Modelo de Aprendizaje

Se utilizó la arquitectura YOLOv8 en su versión `yolov8n` por su eficiencia y velocidad. El entrenamiento se realizó durante 200 épocas, aplicando técnicas de augmentación para mejorar la robustez del modelo.

3.4 Métricas de Desempeño

Las métricas utilizadas para evaluar el modelo fueron:

- Precisión (Precision)
- Sensibilidad (Recall)
- F1-score

- Matriz de confusión

Además, se generó un archivo `resultados.csv` que almacenó las predicciones para cada imagen de prueba.

4 Resultados y Discusión

4.1 Métricas de Desempeño

Para evaluar la calidad del modelo se utilizaron métricas estándar de aprendizaje automático. La Tabla 2 muestra las métricas calculadas a partir del archivo `resultados.csv`. Los valores reflejan las dificultades en clases donde solo se identificó correctamente 1 de 2 imágenes.

Table 2: Métricas de desempeño por clase.

Clase	Precisión	Recall	F1-score
あ	1.00	0.50	0.67
い	1.00	1.00	1.00
う	1.00	0.50	0.67
え	1.00	0.50	0.67
お	1.00	1.00	1.00

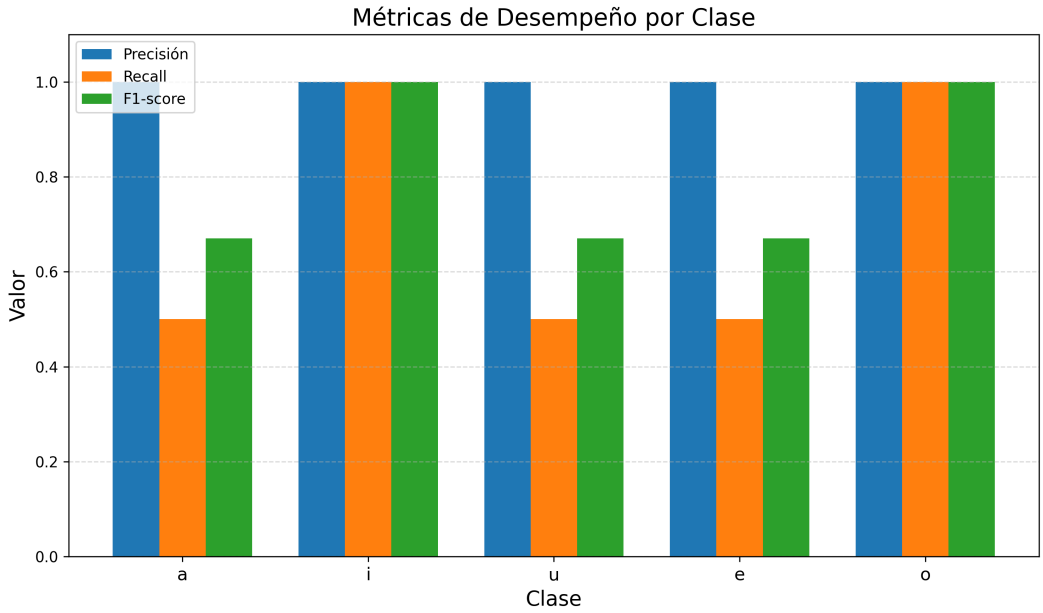

Figure 1: Gráfica comparativa de precisión, recall y F1-score por clase.

Los resultados muestran que el modelo presenta un buen desempeño en algunas clases como い y お, pero dificultades en distinguir correctamente あ, う y え, lo cual coincide con las observaciones realizadas en la matriz de confusión.

4.2 Matriz de Confusión

La Figura 2 presenta la matriz de confusión generada a partir del archivo `resultados.csv`. Los valores diferentes de cero se muestran en azul y los ceros en un tono rojo suave.

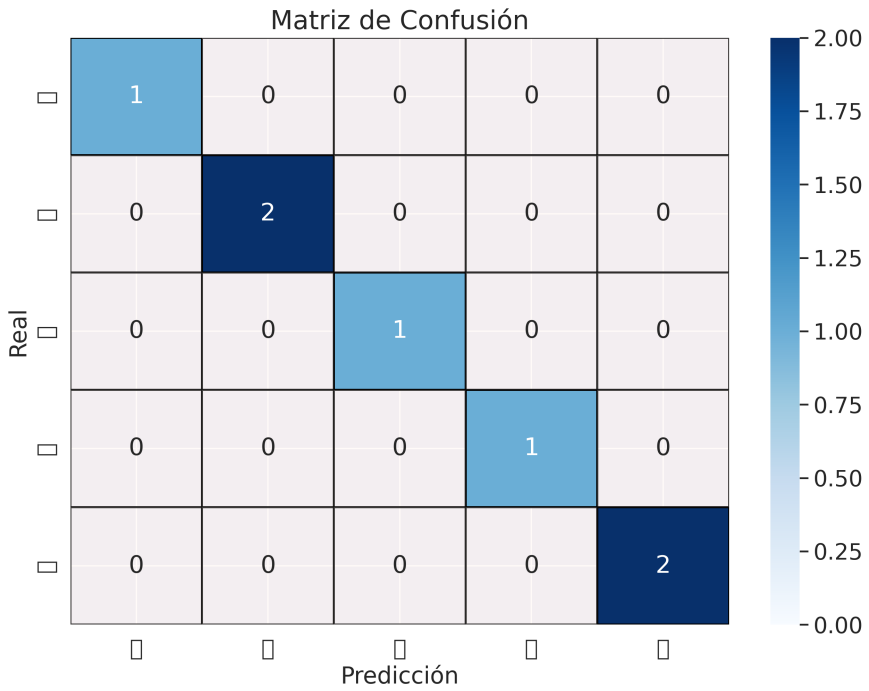

Figure 2: Matriz de confusión del modelo YOLOv8 para detección de vocales hiragana.

El análisis muestra confusiones entre caracteres con trazos similares o con variabilidad en la escritura.

5 Conclusiones

El modelo entrenado logró identificar las vocales del hiragana con un rendimiento aceptable, demostrando que arquitecturas como YOLOv8 pueden aplicarse incluso en proyectos de pequeña escala si se realiza un proceso adecuado de etiquetado y preparación de datos. No obstante, el dataset utilizado fue reducido, lo cual explica el desempeño más bajo en algunas vocales como あ y う, donde las muestras presentaban mayor variabilidad visual. La

expansión del dataset es una mejora fundamental para futuras versiones del modelo. Incluir más imágenes reales, variaciones de estilo, iluminación y tipografías permitirá una mejor generalización del modelo y un incremento en las métricas globales. Además, este sistema puede servir como base para aplicaciones más completas como motores de búsqueda semántica, herramientas educativas, OCR para japonés y sistemas interactivos de reconocimiento. Integrar la detección con embeddings lingüísticos permitiría construir plataformas capaces de interpretar palabras, reconocer escritura del usuario y asistir en el aprendizaje del idioma japonés.

6 Referencias

- Bochkovskiy, A., Wang, C.-Y., & Liao, H.-Y. M. (2020). *YOLOv4: Optimal Speed and Accuracy of Object Detection.* arXiv:2004.10934.
- Redmon, J., & Farhadi, A. (2018). *YOLOv3: An Incremental Improvement.* arXiv:1804.02767.
- Ultralytics. (2024). *YOLOv8 Documentation.* Recuperado de `https://docs.ultralytics.com`
- Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow.* O'Reilly Media.